

Capítulo 3

Algoritmos Genéticos

Historicamente, as primeiras iniciativas na área da Computação Evolutiva foram de biólogos e geneticistas interessados em simular os processos vitais de um ser humano em um computador, na época (final da década de 50) foram denominados de “processos genéticos”. Na década de 60, o cientista *John Holland* iniciou um estudo [12], no qual era implementado uma população de indivíduos os quais possuíam cromossomos e eram sujeitos a operações de seleção, mutação e cruzamento. Desse estudo foram criados os Algoritmos Genéticos.

Os Algoritmos Genéticos são métodos generalizados de busca e otimização que simulam os processos naturais de evolução, baseados nas idéias de seleção natural propostas por *Charles Darwin* [13], visando aplicá-las na resolução de problemas reais, como maximização e minimização de funções. Nessas simulações há uma população de indivíduos, os quais possuem uma constituição genética (cromossomo) que são codificações de soluções de um problema. Os indivíduos serão selecionados com o passar das gerações (iterações do algoritmo) em busca de melhores soluções. Geralmente, o conjunto de soluções iniciais é criado aleatoriamente e a cada geração esse conjunto é evoluído. Para simular o efeito de evolução, utilizam-se critérios de avaliação e seleção dos indivíduos. O primeiro determina a aptidão (ou *fitness*), enquanto que o segundo seleciona, de forma determinística ou probabilística, os indivíduos com maior aptidão que irão compor as gerações futuras. Assim, a tendência é que ao longo das gerações os indivíduos mais aptos sobrevivam e conseqüentemente ocorra a convergência para uma solução ótima (ou aproximadamente ótima) do problema, já que cada indivíduo representa uma solução.

Para cada tipo de problema pode haver uma maneira específica de se avaliar os indivíduos. Tomando um simples problema como exemplo: minimizar a função quadrática $f(x) = x^2$ no domínio $D(f) = [0,15]$. Para esse caso, um número real

pertencente ao domínio da função pode ser um possível cromossomo de um indivíduo. Certas abordagens de Algoritmos Genéticos codificam o cromossomo dos indivíduos de forma binária. Supondo uma população inicial de 2 indivíduos, na qual cada um possui um cromossomo que é um número binário. A avaliação dos indivíduos é realizada de acordo com o Algoritmo 1.

Algoritmo 1. Avaliação dos indivíduos.

1. Converter valor do cromossomo para número decimal;
2. Usar o número encontrado como argumento (x) da função
3. Usar o valor de $f(x)$ como aptidão do indivíduo

A Tabela 1 mostra um exemplo com cromossomos dos 2 indivíduos da população, gerados aleatoriamente, e os valores correspondentes de x e $f(x)$. Como este exemplo trata de um problema de minimização, o indivíduo de G1 é considerado mais apto que o G2, pois seu cromossomo corresponde a um valor mais próximo ao mínimo da função.

Tabela 1. Cromossomos de indivíduos e função de avaliação.

	Cromossomo	x	$f(x)$
G1	0001	1	1
G2	0101	5	25

A função que se deseja otimizar no problema é denominada função objetivo (ou *fitness function*). No exemplo descrito esta função era simples e conhecida ($f(x) = x^2$), no entanto os Algoritmos Genéticos são, geralmente, aplicados em problemas complexos de otimização. A grande vantagem dos Algoritmos Genéticos está no fato de não ser necessário saber como funciona a função objetivo, é preciso apenas tê-la disponível para aplicar aos indivíduos, comparar os resultados e conhecer o formato das entradas. Sendo assim, as aplicações são para problemas com diversos parâmetros ou características que precisam ser combinadas em busca da melhor solução; problemas com muitas restrições ou condições que não podem ser representadas matematicamente; e problemas com grandes espaços de busca.

Alguns exemplos são: Otimização Combinatória [14], Problema do Caixeiro Viajante (TSP - *Traveling Salesman Problem*) [15], Otimização de Síntese de Circuitos Eletrônicos [16], dentre outras aplicações.

Essa gama de aplicações para os Algoritmos Genéticos não seria possível apenas com os critérios que definem a aptidão dos indivíduos e o operador de seleção. Se utilizado somente esse operador a busca por soluções ficaria limitada apenas ao conjunto inicial de soluções, uma vez que não há alteração das soluções geradas. Por isso, outros dois operadores são empregados nos Algoritmos Genéticos, o operador de mutação e o de cruzamento (ou recombinação). O primeiro realiza alterações no cromossomo dos indivíduos e o segundo faz combinações entre dois indivíduos (os pais) gerando um terceiro (um filho) com o cromossomo constituído pela combinação dos cromossomos dos pais. Com isso, os novos cromossomos gerados, sejam por mutação ou por cruzamento, irão constituir novas soluções e, por conseguinte, irão diversificar o conjunto de soluções aumentando a capacidade de exploração do algoritmo e contribuindo para a busca por melhores soluções. O funcionamento desses três operadores (seleção, cruzamento e mutação) será detalhado na seção 3.2.

3.1 Representação dos Indivíduos

Como citado no início deste capítulo, um indivíduo é uma representação de uma solução. Eles possuem dois atributos básicos:

Cromossomo: Codificação de uma solução. O cromossomo deve ser uma representação capaz de cobrir todo o conjunto dos valores no espaço de busca, e deve ter tamanho finito. Geralmente o cromossomo é uma seqüência de bits. Além da representação binária, também se utilizam seqüências de números inteiros, números reais, letras, ou outros tipos de dados específicos de um problema abordado. Essas seqüências são, comumente, colocadas em *arrays*, pois facilitam as operações de cruzamento e mutação. Para problemas com múltiplas entradas é possível combinar as entradas (genes do indivíduo) em uma única seqüência de bits como mostra a Figura 7.




Figura 7. Cromossomo binário com duas entradas.

- Aptidão (ou *fitness*): Qualidade da solução representada pelo indivíduo. É um atributo importante no momento de aplicação dos operadores sobre a população. Na seleção, os indivíduos mais aptos têm maior tendência de serem escolhidos do que os indivíduos menos aptos. No cruzamento, os indivíduos mais aptos terão maior possibilidade de se combinarem para gerar novas soluções. Por fim, na mutação, certa quantidade de indivíduos mais aptos não sofre a ação desse operador, para que as melhores soluções perdurem ao longo das gerações. Essa técnica é chamada de elitismo e será detalhada na seção 3.2.

3.2 Operadores

Nos Algoritmos Genéticos os operadores são fundamentais para o sucesso desse método de busca. Sem eles não seria possível realizar busca em amplitude e em profundidade no espaço de soluções:

- Busca em amplitude: consiste em visitar regiões que ainda não foram visitadas no espaço de busca, para tal é preciso criar diversidade no conjunto de soluções. Isso irá aumentar a capacidade de exploração (*exploration*) do algoritmo.
- Busca em profundidade: consiste em concentrar a busca em regiões mais promissoras do espaço de busca, ou seja, regiões onde se encontram boas soluções para o problema. Esse tipo de busca tende a refinar as soluções encontradas de maneira que elas converjam para um ponto, podendo ser um máximo (ou mínimo) global ou local. A busca em profundidade está ligada à capacidade de prospecção (*exploitation*) do algoritmo.

Uma boa técnica de otimização deve combinar esses aspectos, *exploration* e *exploitation*, para encontrar a solução ótima (ou aproximadamente ótima) de um

problema (i.e. máximo ou mínimo global). Os Algoritmos Genéticos combinam ambos os aspectos através dos operadores de seleção (*exploitation*), mutação e cruzamento (*exploration*).

3.2.1 Cruzamento

O operador de cruzamento é conhecido também como operador de recombinação. Ele combina os cromossomos de dois indivíduos pais gerando um filho na população. Para descrever o funcionamento desse operador serão considerados dois indivíduos cujos cromossomos de tipo binário são mostrados na Figura 8. A diferença de cores nos cromossomos do PAI A e do PAI B é apenas para facilitar a visualização nos exemplos.




Figura 8. Indivíduos que serão cruzados.

Existem várias formas de realizar a operação de cruzamento. Três dessas formas serão explicadas:

- Cruzamento de ponto único: é escolhido um ponto de cruzamento aleatoriamente, em seguida é copiado parte do cromossomo de cada pai, depois as partes são concatenadas gerando o cromossomo de um filho. Uma parte desse filho é formada pelos bits que vão do primeiro até o ponto de cruzamento de um pai e pelos bits que vão do ponto de cruzamento até o último bit do outro pai. A Figura 9 ilustra esta operação.

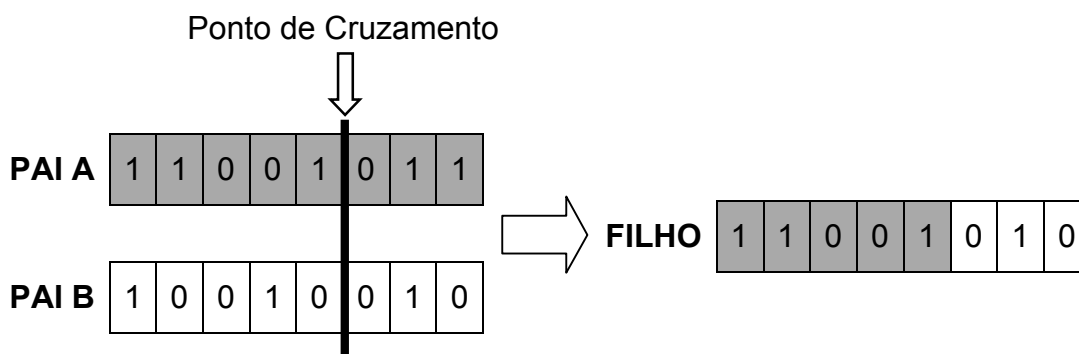


Figura 9. Cruzamento de ponto único.

- Cruzamento de dois pontos: são escolhidos dois pontos de cruzamento aleatoriamente, em seguida é copiado parte do cromossomo de cada pai, depois as partes são concatenadas gerando o cromossomo de um filho. Uma parte desse filho é formada pelos bits que estão dentro da faixa gerada pelos pontos de cruzamento em um pai e pelos bits que estão fora da faixa no outro pai. A Figura 10 ilustra esta operação.

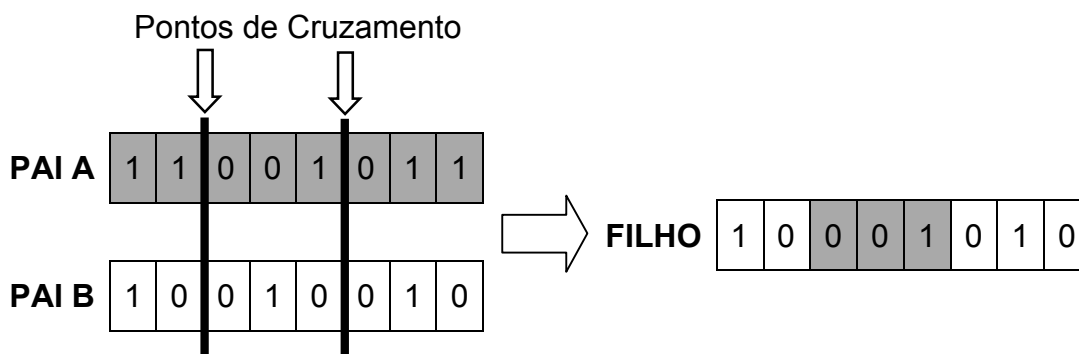


Figura 10. Cruzamento de dois pontos.

- Cruzamento uniforme ou multiponto: é gerado um indivíduo a partir de bits copiados aleatoriamente do primeiro ou do segundo pai. A Figura 11 ilustra esta operação.




Figura 11. Cruzamento uniforme.

Em cada tipo de cruzamento há a opção de gerar um ou dois indivíduos (é uma escolha de implementação, que pode variar dependendo do problema). No caso de serem gerados dois indivíduos o segundo indivíduo será formado pelas partes que foram desprezadas de cada pai ao gerar o primeiro indivíduo.

3.2.2 Mutação

O papel principal do operador de mutação é mudar aleatoriamente parte das informações codificadas de um cromossomo para criar novas soluções. Por outro lado, a operação de mutação pode ser empregada para reordenar codificações

inválidas (não pertencentes ao espaço de busca), obtendo novas soluções viáveis e válidas.

No caso de indivíduos de cromossomo de tipo binário, a operação de mutação irá escolher alguns bits aleatoriamente e invertê-los. No caso de dos cromossomos de tipo inteiro ou real, quando um número é escolhido pra sofrer mutação este será substituído por outro número gerado aleatoriamente. A Figura 12 mostra a operação de mutação; os bits que têm preenchimento branco são os alterados.




Figura 12. Operação de mutação.

3.2.3 Seleção

O operador de seleção é inspirado na idéia da seleção natural. Assim, a cada geração, os melhores indivíduos (mais aptos) são selecionados para gerar filhos através de cruzamento e mutação. Esse operador conduz as soluções para as melhores regiões do espaço de busca.

Um método seleção é o de Exclusão Social [17]. Primeiramente, a população é ordenada em ordem decrescente de aptidão, cada indivíduo irá cruzar com o indivíduo de aptidão imediatamente inferior a sua e gerar um filho. Em outras palavras, o indivíduo mais apto da população cruzaria com o segundo mais apto, o terceiro com o quarto e assim por diante. Poderia também ser da seguinte forma: o primeiro mais apto cruza com o segundo mais apto, este cruza com o terceiro mais apto e assim por diante. Neste trabalho, por decisão de projeto, os experimentos utilizaram apenas primeira abordagem descrita para a Exclusão Social.

Há outro método de seleção, este bastante típico, que é a seleção proporcional à aptidão, também conhecida como Seleção por Roleta. Os indivíduos são selecionados de forma probabilística. Cada um tem a probabilidade de ser

escolhido proporcionalmente à sua aptidão (i.e. quanto mais apto mais terá chance de ser selecionado). A Figura 13 mostra um exemplo de roleta com quatro indivíduos.




Figura 13. Roleta com seções proporcionais à aptidão dos indivíduos.

Ao “girar” esta roleta o indivíduo 1 terá a maior probabilidade de ser selecionado. Esse processo pode ser descrito segundo o Algoritmo 2.

Algoritmo 2. Pseudocódigo da roleta.

1. Calcule a soma T dos valores de aptidão de todos os indivíduos da população.
2. Ordene a população de ordem decrescente de aptidão.
3. Gere um número aleatório r no intervalo $[0, T]$.
4. Percorra toda a população somando as aptidões dos indivíduos (soma s). Quando a soma s for maior que r , pare e retorne o indivíduo atual.

3.2.4 Elitismo

O cruzamento e a mutação podem excluir o melhor indivíduo da população. Para evitar que a melhor (ou as melhores) solução seja descartada da população emprega-se essa técnica chamada elitismo [18]. Esse operador garante que os n melhores indivíduos sejam repassados para a geração seguinte.

3.3 Parâmetros dos Algoritmos Genéticos

Nesta seção serão explicados alguns parâmetros existentes nessa técnica:

- **Tamanho da População:** Determina o número de indivíduos da população inicial. É possível que a quantidade de indivíduos varie numa mesma geração devido às operações de cruzamento, mas ao final de cada geração a população deve estar com o mesmo tamanho da população inicial, ou seja, alguns indivíduos são descartados. O parâmetro em questão afeta diretamente o desempenho global e a eficiência dos Algoritmos Genéticos. Com uma população pequena, o desempenho pode ser insatisfatório, pois assim a população fornece pouca cobertura do espaço de busca do problema. Uma grande população geralmente fornece maior cobertura do domínio do problema, além de prevenir convergências prematuras para máximos (ou mínimos) locais ao invés de globais. No entanto, o aumento da população, gera um aumento no custo computacional do algoritmo.
- **Taxa de Cruzamento:** Quanto maior for esta taxa, mais rapidamente novos indivíduos serão introduzidos na população. Mas se esta for muito alta, a maior parte da população pode ser substituída, aumentando a possibilidade de ocorrer perda de indivíduos de alta aptidão. Com um valor baixo, o algoritmo pode tornar-se muito lento, afetando a velocidade de convergência, já que serão gerados poucos indivíduos novos a cada geração. Logo, reduz a capacidade de busca em amplitude.
- **Taxa de Mutação:** Determina a probabilidade com que uma mutação ocorrerá. Uma baixa taxa de mutação previne que um dado indivíduo fique estagnado no espaço de busca. Com uma taxa muito alta a busca se torna essencialmente aleatória além de aumentar muito a possibilidade de que uma boa solução seja destruída. A Taxa de Mutação é dependente da aplicação, mas para a maioria dos casos é entre 1 e 10%.
- **Taxa de Elitismo:** Determina a taxa de indivíduos mais aptos que serão repassados para a próxima geração. Se essa taxa for muito alta pode acarretar em estagnação na busca, pois muitos indivíduos de uma geração serão automaticamente repassados para a geração seguinte. Isto reduzirá a

diversificação da população ao longo das gerações. Então as taxas mais baixas são as mais empregadas. Em muitos casos apenas o melhor indivíduo da população é automaticamente repassado para a geração seguinte.

3.4 Fluxo de execução dos Algoritmos Genéticos

Nesta seção será explicado o fluxograma básico dos Algoritmos Genéticos.

Inicialmente cria-se a população. Os cromossomos dos indivíduos presentes nessa primeira geração podem ser gerados aleatoriamente ou gerados nas regiões mais promissoras do espaço de busca. Essa segunda forma é possível quando se tem um conhecimento prévio sobre o espaço de busca do problema. Em seguida cada indivíduo é avaliado de acordo com a função de avaliação do problema para definir a aptidão. Após a fase de avaliação, testa-se um critério de parada, que é a condição na qual se considera que o algoritmo encontrou uma solução aceitável ou simplesmente quando se atingir a quantidade máxima de gerações estipuladas inicialmente. Caso o critério de parada tenha sido satisfeito então o melhor indivíduo é apresentado como a solução do problema e a execução é encerrada. Caso contrário, aplicam-se os operadores na população, em seguida partindo para a próxima geração (nova iteração do algoritmo). O algoritmo retorna à fase de avaliação e segue os passos já descritos. A Figura 14 mostra o fluxograma de execução do algoritmo.

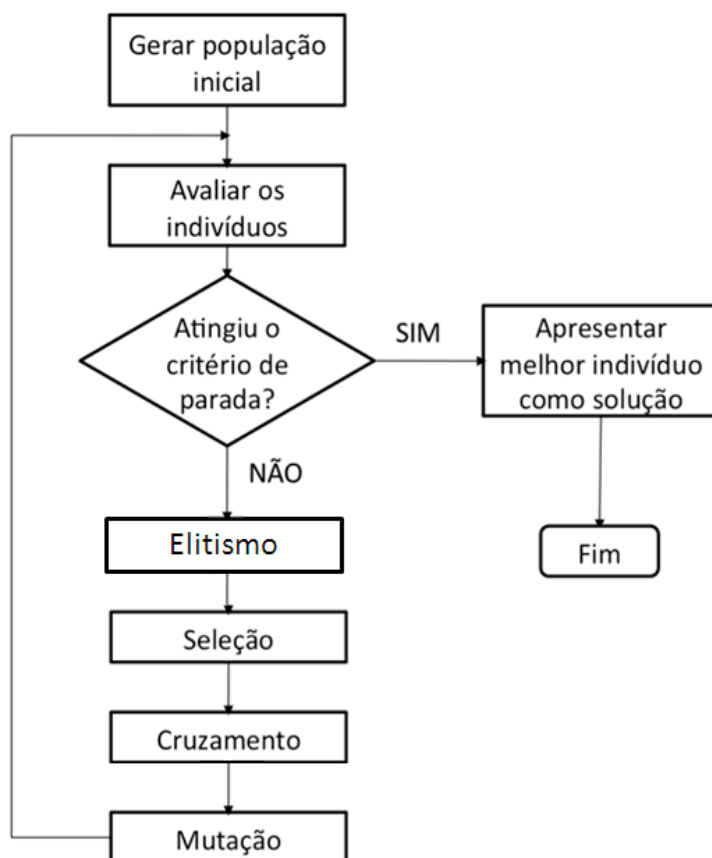


Figura 14. Fluxograma básico de execução do Algoritmo Genético.