


Redes Neurais Artificiais


Motivação às RNA's

- Úteis quando não se pode formular uma solução algorítmica
- Necessidade de extrair uma estrutura dos dados existentes
- Tolerância a certa imprecisão
- Problemas para os quais regras rápidas e rígidas não podem ser aplicadas (sistemas especialistas).
- Adaptação e aprendizagem
- **Classificação e aproximação de funções**

Inspiração biológica




Neurônio Artificial - MCP



Topologia de RNA


- Feedforward

- Conexões não formam ciclos, sinais unidirecionais
- Da camada de entrada para a de saída
- Simplicidade, estabilidade
- Treinamento mais fácil

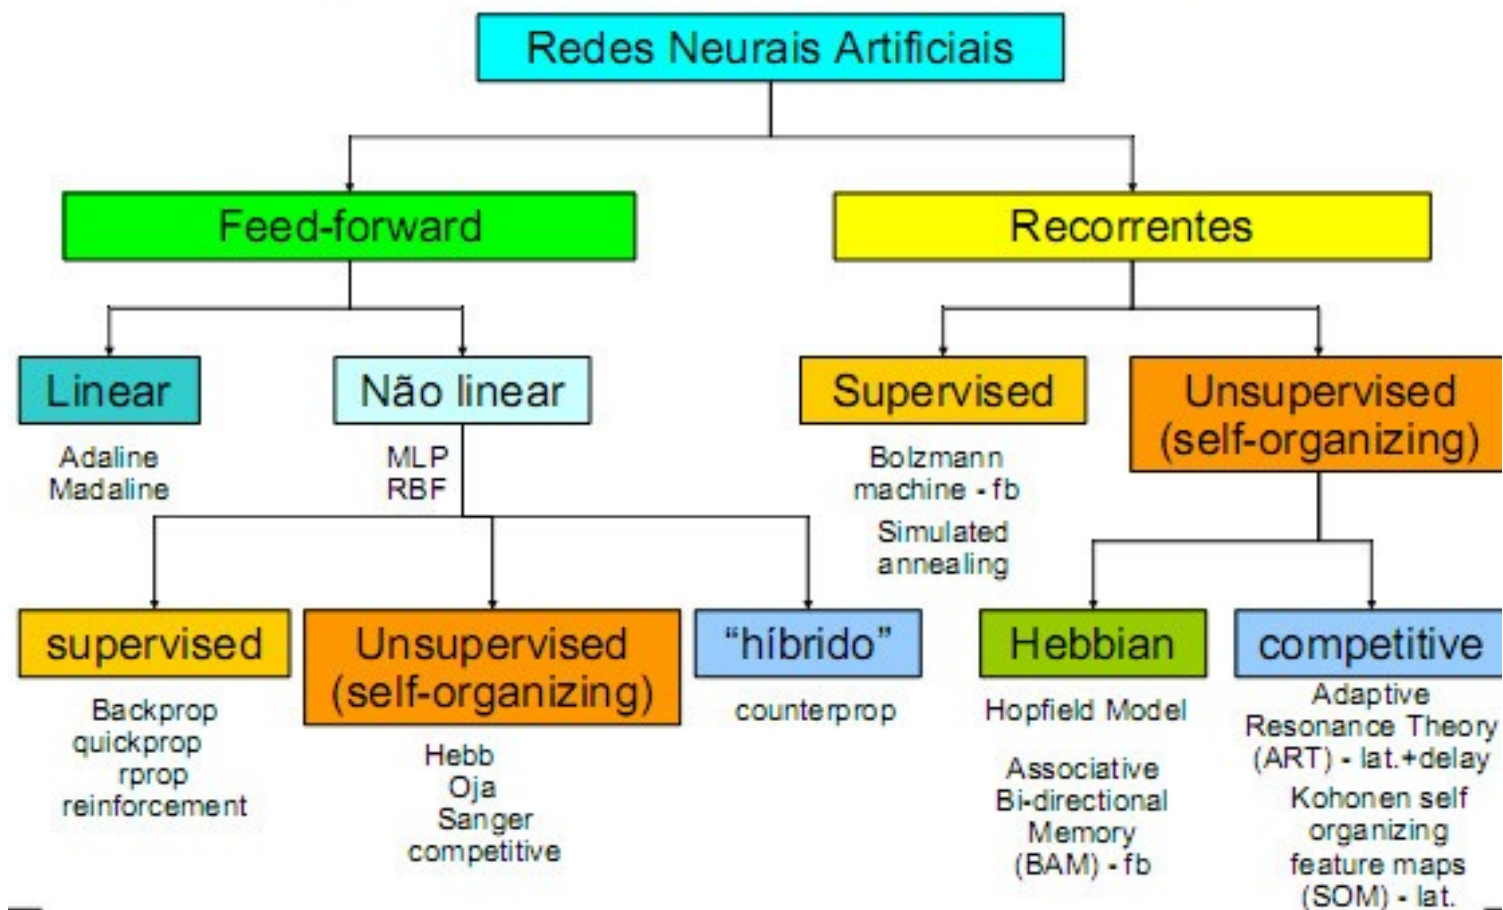


- Feedback

- Há ciclos entre as conexões, iterações
- Sinais multidirecionais
- Tempo de resposta maior
- Geralmente mais difíceis de treinar




Tipos de RNA




Aplicações


- Classificação, previsão, reconhecimento de padrões



Proc. sinais



Proc. voz




Diagnose
médica



Análise de
crédito



Data mining



Análise de
mercado

Exemplo


- Perceptron
 - Em 1957, no Cornell Aeronautical Laboratory, por Frank Rosenblatt
 - Unidades básicas: nodos MCP
 - Única camada
 - Sempre convergem em problemas linearmente separáveis

Problema

- Treinamento e classificação para o seguinte problema:
 - Reconhecer os caracteres T e H
 - Pesos iniciais = 0
 - Taxa de aprendizagem = 1
 - Treinamento com 3 ciclos (ou épocas)

Resolução

- Como modelar o problema?
- Quantas entradas? Qual limiar de ativação?



Treinamento

- Correção dos pesos
 - $w(ij)' = w(ij) + \alpha(\delta_i - y_i)x(j)$
 - $y = f(Net) // f(Net) \gg \text{função degrau}$
 - $Net = \text{somatório}(X_j * W_{ij})$

Classificação

- Calcular $f(\text{Net})$ para uma entrada
- Checar com a codificação adotada na modelagem
- Testem a rede para os caracteres T e H distorcidos.